

Análise de sentimento de críticas de cinema em português com deep learning

Sep 26, 2026 · @Samir

Autores: Samir Saraiva, Claudio Cruz, Vinicius Ferreira e João Felipe

Resumo

Modelos de sentimento treinados com dados fora do domínio falham em críticas de cinema reais, mesmo com alta acurácia no teste. Uma Bi-LSTM treinada em avaliações de produtos (B2W) atingiu 95,4% no teste, mas apenas 46% em 50 críticas de cinema rotuladas manualmente — abaixo da linha de base de 56%.

Este trabalho compara dois modelos de deep learning em Keras: uma Bi-LSTM treinada do zero e o BERTimbau (BERT pré-treinado em português) com fine-tuning. Cada modelo é treinado em três cenários: críticas do IMDB traduzidas automaticamente, críticas nativas em português coletadas do Papo de Cinema e do AdoroCinema, e as duas fontes juntas.

A avaliação usa conjuntos divididos por filme e um conjunto ouro independente. O BERTimbau treinado com IMDB e críticas nativas foi o melhor em todos os testes: F1 de 0,892 em 916 críticas do Papo de Cinema e 82% de acerto no conjunto ouro ($p < 0,001$ contra a linha de base). Os dados nativos elevaram o reconhecimento de críticas negativas no ouro de 27% para até 82%. A Bi-LSTM não conseguiu aprender só com as 3.192 críticas nativas.

Palavras-chave: análise de sentimento; LSTM bidirecional; BERTimbau; mudança de domínio; web scraping.

1. Introdução

Medir como o público recebe um filme é um problema de negócio real para distribuidoras, exibidores e plataformas de streaming. A opinião está em texto livre: críticas profissionais, avaliações de espectadores e discussões em fóruns. Classificar esse texto automaticamente é a tarefa de análise de sentimento.

Para o português, há poucos conjuntos rotulados de críticas de cinema. A saída comum é treinar com dados de outro domínio, como avaliações de produtos, ou com traduções automáticas de bases em inglês. O risco é o modelo ir bem no teste e mal no mundo real.

Objetivo. Construir e avaliar modelos de deep learning que classifiquem críticas de cinema em português como positivas ou negativas, medindo o desempenho em críticas reais que não fizeram parte do treino.

Perguntas de pesquisa.

1. A acurácia no conjunto de teste prevê o desempenho em críticas reais de outro domínio?
2. Treinar com críticas nativas em português melhora a generalização em relação a dados traduzidos?
3. Um modelo pré-treinado em português (BERTimbau) generaliza melhor que uma Bi-LSTM treinada do zero?

Contribuições.

- Um corpus de críticas nativas em português com rótulo derivado da nota, coletado de duas fontes com perfis diferentes (críticos e espectadores).
- Uma comparação controlada: 2 modelos $\times$ 3 cenários de treino, avaliados nos mesmos conjuntos de teste.
- Evidência quantitativa do efeito da mudança de domínio, com intervalos de confiança.

2. Fundamentação teórica

Análise de sentimento. É a classificação da polaridade de um texto (positivo ou negativo). Aqui ela é tratada como classificação binária supervisionada, com rótulos derivados de notas numéricas.

Embeddings. Cada palavra, ou parte de palavra, é representada por um vetor denso aprendido. Palavras com uso parecido ficam próximas no espaço vetorial.

LSTM bidirecional. A LSTM é uma rede recorrente com memória controlada por portões, o que reduz o problema do gradiente que desaparece em sequências longas (HOCHREITER; SCHMIDHUBER, 1997). A versão bidirecional lê o texto nos dois sentidos, captando o contexto antes e depois de cada palavra.

Transformers e BERT. O Transformer substitui a recorrência por atenção: cada token pondera todos os outros da sequência (VASWANI et al., 2017). O BERT é um encoder Transformer pré-treinado em grandes corpora por modelagem de linguagem mascarada (DEVLIN et al., 2019). Para classificar, adiciona-se uma camada sobre o token [CLS] e ajusta-se o modelo com poucos exemplos rotulados (fine-tuning).

BERTimbau. É o BERT pré-treinado em português do Brasil, no corpus brWaC, com cerca de 2,7 bilhões de tokens (SOUZA; NOGUEIRA; LOTUFO, 2020). A versão base tem 12 camadas e cerca de 110 milhões de parâmetros.

Transfer learning e mudança de domínio. Um modelo treinado numa distribuição de dados (domínio de origem) tende a perder desempenho em outra (domínio de destino). As causas são diferenças de vocabulário, de estilo e de como o sentimento é expresso.

Uma reclamação de produto ("chegou quebrado") e uma crítica negativa de cinema ("bonito, barulhento e superficial") expressam insatisfação de formas muito diferentes.

3. Dados

O trabalho usa cinco fontes, que diferem em domínio, idioma de origem e autoria. As duas fontes nativas foram coletadas por web scraping próprio. O conjunto ouro nunca entra no treino.

Fonte	Tipo de texto	Idioma de origem	Rótulo	Uso	Tamanho
B2W-Reviews01	Avaliações de produtos (REAL; OSHIRO; MAFRA, 2019)	Português	Nota 1-2 negativo, 4-5 positivo	Experimento 1	~67,5 mil (balanceado)
IMDB PT-BR (Kaggle)	Críticas de usuários do IMDB (MAAS et al., 2011)	Inglês, tradução automática	pos/neg original	Treino e teste	~49 mil
Papo de Cinema	Críticas profissionais (~950 palavras)	Português	Nota do crítico, 0-10	Treino e teste	5.762 rotuladas (5.762 filmes)
AdoroCinema	Críticas de espectadores (~60 palavras)	Português	Estrelas, 0,5-5	Treino e teste	1.269 rotuladas (78 filmes)
Conjunto ouro	Críticas do Cinema com Rapadura e do Omelete	Português	Rapadura: manual; Omelete: nota	Só teste	50 (22 neg., 28 pos.)

Rotulagem pela nota. A nota é normalizada para o intervalo 0-1. Nota $\geq 0,7$ vira positivo (ex.: 7/10, 3,5/5) e $\leq 0,4$ vira negativo (ex.: 4/10, 2/5). As notas intermediárias ficam de fora, porque são ambíguas.

Conjunto ouro. O Cinema com Rapadura não publica nota. Por isso, as 40 críticas coletadas dele foram rotuladas manualmente pelos autores deste trabalho, com base no veredito do texto. As ambíguas foram descartadas. As 10 do Omelete usam a nota publicada.

Coleta ética. O coletor respeita o robots.txt de cada site e se identifica com um User-Agent honesto. Ele espera pelo menos 1 segundo entre requisições e não armazena dados pessoais: o nome do usuário não é salvo. As páginas ficam em cache local, o que evita baixar a mesma página duas vezes.

Tentativas descartadas. O X/Twitter e a API do Reddit exigem aprovação para acesso. Instagram, Threads, Spotify e YouTube bloqueiam coleta automatizada ou não expõem comentários com nota. Esses obstáculos direcionaram a escolha para portais de crítica com nota explícita.

Corpus nativo coletado. Em cerca de 4h35 de coleta, foram baixadas 7.196 páginas, sem erros, e reunidas 10.030 críticas. Destas, 7.031 têm nota fora da faixa neutra e entram no treino e no teste.

Fonte	Coletadas	Negativas	Neutras (fora)	Positivas	Treino	Validação	Teste	Palavras (mediana)
Papo de Cinema	8.579	2.111	2.817	3.651	3.992	854	916	751
AdoroCinema	1.451	236	182	1.033	676	424	169	44
Total	10.030	2.347	2.999	4.684	4.668	1.278	1.085	—

Em 257 críticas (2,6%) a nota não pôde ser extraída, provavelmente páginas antigas sem a tabela "Grade crítica". Elas ficaram de fora.

O AdoroCinema tem 81% de críticas positivas e só 78 filmes. Com poucos filmes, a divisão por filme fica desigual entre as partições (424 na validação contra 169 no teste). O Papo de Cinema tem uma crítica por filme, então a divisão sai próxima de 70/15/15.

4. Metodologia

Os dois modelos foram implementados em Keras sobre TensorFlow (CHOLLET et al., 2015; ABADI et al., 2015) e são treinados e avaliados exatamente nos mesmos dados, o que isola o efeito do modelo e o efeito da fonte de treino.

Pré-processamento. Textos sem nenhuma letra ou número são descartados. Críticas longas são reduzidas mantendo o início e o fim: metade do limite de palavras de cada ponta, porque o veredito costuma estar no fim.

Divisão por filme. As críticas nativas são divididas em 70% treino, 15% validação e 15% teste, pelo hash do identificador do filme. Todas as críticas de um filme caem na mesma partição. Assim, o modelo não é testado em um filme que viu no treino.

Balanceamento. No treino, a classe majoritária é subamostrada até 50/50, separadamente em cada fonte. O AdoroCinema tem cerca de 3 positivas para cada negativa. Os conjuntos de teste mantêm a distribuição natural.

Modelos.

	Bi-LSTM	BERTimbau
Inicialização	Aleatória (do zero)	Pré-treinado (brWaC)
Tokenização	Palavras, vocabulário de 20 mil aprendido no treino	WordPiece, vocabulário de 29.794
Arquitetura	Embedding 64 → Bi-LSTM 64 → Dropout 0,4 → Dense 32 → saída sigmoide	12 camadas Transformer (768) → [CLS] → Dropout 0,1 → saída sigmoide
Parâmetros	~1,35 milhão	~109 milhões (todos treináveis)
Comprimento	300 palavras	256 tokens (200 palavras, início e fim)
Otimizador	Adam	AdamW, lr 2e-5, aquecimento de 10% e decaimento cosseno
Épocas	Até 15, lote 32, parada antecipada (paciência 3)	Até 2, lote 16, parada antecipada (paciência 1)

Restrição de hardware. O fine-tuning completo do BERT-base com Adam exige cerca de 3 GB de memória de vídeo. A RTX 3050 Laptop usada tem 4 GB, mas só cerca de 2 GB ficam livres com o vídeo do sistema na mesma placa. Em vez de congelar as 8 primeiras camadas do BERTimbau, como no teste preliminar, todas as 12 camadas são ajustadas. Para isso, o BERTimbau foi treinado no Google Colab, numa GPU NVIDIA T4 de 16 GB, com lote de 16; a Bi-LSTM foi treinada localmente [trocar se o Colab falhar e o treino for feito no PC com a GPU liberada]. Usa-se precisão mista (float16).

Cenários de treino. (a) IMDB PT-BR; (b) nativo: Papo de Cinema + AdoroCinema; (c) IMDB PT-BR + nativo.

Métricas. Acurácia com intervalo de confiança de 95% (WILSON, 1927) e linha de base (acerto de quem sempre chuta a classe majoritária). Também F1 macro, que não é inflado pelo desbalanceamento, e precisão e recall por classe, com matriz de confusão.

5. Experimento 1: produtos vs cinema traduzido

A acurácia no teste não previu o desempenho em críticas reais: o modelo com a maior acurácia no teste foi o pior nas críticas de cinema. Nos dois casos, a Bi-LSTM foi avaliada nas mesmas 50 críticas do conjunto ouro.

Treino da Bi-LSTM	Acurácia no teste	Acurácia no conjunto ouro (IC 95%)	Linha de base	Recall negativo	Recall positivo
B2W (produtos)	95,4%	46% (32%–60%)	56%	1,00	0,04
IMDB PT-BR (cinema, traduzido)	88,8%	62% (49%–75%)	56%	0,27	0,89

B2W. O modelo classificou 49 das 50 críticas como negativas. O vocabulário de enredo (morte, conflito, violência, fracasso) soa negativo para um modelo que aprendeu com reclamações de produto. Na prática, ele virou um classificador que só diz "negativo" e ficou abaixo da linha de base.

IMDB PT-BR. Treinar com cinema eliminou o viés negativo, mas criou o oposto: só 6 das 22 críticas negativas foram reconhecidas. A crítica negativa profissional costuma ser nuançada. Já a negativa típica do IMDB é um desabafo de usuário, e ainda passou por tradução automática.

Significância. Com 50 críticas, o intervalo de confiança tem cerca de ± 13 pontos. O ganho do IMDB sobre a linha de base não é estatisticamente significativo (teste binomial, $p \approx 0,24$).

Teste prévio do BERTimbau. Um teste com o BERTimbau treinado em só 2 mil críticas do IMDB, com 1 época e 8 camadas congeladas, deu 88,0% no teste do IMDB, empatando com a Bi-LSTM treinada em 34 mil. No conjunto ouro, deu os mesmos 62%, com o mesmo viés (recall negativo de 0,36). Isso indica que a limitação está nos dados de treino, não no modelo, e motiva o Experimento 2.

6. Experimento 2: modelos $\times$ fontes de treino

O BERTimbau treinado com IMDB + críticas nativas foi o melhor em todos os conjuntos de teste. No conjunto ouro, chegou a 82% de acurácia (IC 95%: 69%–90%), contra linha de base de 56% (teste binomial, $p < 0,001$). Na Bi-LSTM, o melhor resultado no ouro foi 68%, sem significância estatística ($p \approx 0,06$).

Treino	Modelo	IMDB PT-BR (n = 3.000)	AdoroCinema (n = 169)	Papo de Cinema (n = 916)	Conjunto ouro (n = 50)
IMDB PT-BR	Bi-LSTM	0,886	0,834	0,735	0,632
IMDB PT-BR	BERTimbau	0,911	0,947	0,838	0,587
Nativo	Bi-LSTM	0,578	0,628	0,577	0,374
Nativo	BERTimbau	0,877	0,880	0,870	0,799

Treino	Modelo	IMDB PT-BR (n = 3.000)	AdoroCinema (n = 169)	Papo de Cinema (n = 916)	Conjunto ouro (n = 50)
IMDB + nativo	Bi-LSTM	0,877	0,872	0,700	0,667
IMDB + nativo	BERTimbau	0,917	0,954	0,892	0,807

F1 macro por conjunto de teste. A tabela completa, com acurácia, IC 95% e recall por classe, está em dados/resultados/comparacao.md .




Figura 1. F1 macro dos dois modelos nos três cenários de treino, em cada conjunto de teste. A linha tracejada marca 0,5, o nível do acaso.

Recall das críticas negativas no conjunto ouro — a métrica que expunha o viés dos modelos treinados só com o IMDB:

Treino	Bi-LSTM	BERTimbau
IMDB PT-BR	0,36 (8 de 22)	0,27 (6 de 22)
Nativo	0,32 (7 de 22)	0,82 (18 de 22)
IMDB + nativo	0,55 (12 de 22)	0,64 (14 de 22)

Efeito da fonte de treino. Treinado só no IMDB, o BERTimbau teve o melhor resultado entre os modelos no teste do próprio IMDB (91,1%), mas ficou em 66% no conjunto ouro, reconhecendo só 6 das 22 críticas negativas. Com críticas nativas no treino, o F1 no ouro subiu de 0,587 para 0,799 (só nativo) e 0,807 (combinado). No Papo de Cinema, com 916 críticas, o F1 subiu de 0,838 para 0,892.

Efeito do modelo. O BERTimbau superou a Bi-LSTM em 11 dos 12 pares comparáveis. A exceção foi o conjunto ouro no cenário IMDB (0,587 contra 0,632), diferença dentro da margem de erro de 50 críticas. A maior diferença foi no cenário nativo: com 3.192 exemplos, a Bi-LSTM decorou o treino (98% de acerto no treino contra 57% na validação) e ficou abaixo da linha de base no Papo de Cinema. Já o BERTimbau chegou a F1 de 0,870 com os mesmos dados.

Generalização entre críticos e espectadores. Treinado com o corpus nativo, dominado por críticos (2.942 de 3.192 exemplos), o BERTimbau teve F1 de 0,880 nas críticas de espectadores do AdoroCinema e de 0,877 no IMDB traduzido. O modelo transferiu bem entre estilos de texto muito diferentes: críticas de ~750 palavras no treino e de ~44 palavras no teste.

Custo. Cada época do BERTimbau levou de 2 a 11 minutos numa GPU T4, com cerca de 525 ms por lote de 16. Uma época da Bi-LSTM levou cerca de 20 segundos na RTX 3050. O BERTimbau tem 80 vezes mais parâmetros (108 milhões contra 1,35 milhão).

7. Discussão e limitações

P1 — A acurácia no teste prevê o desempenho em críticas reais? Não. Nos dois experimentos, o modelo com a maior acurácia no teste do próprio domínio não foi o melhor nas críticas reais. A Bi-LSTM do B2W teve 95,4% no teste e 46% no ouro. O BERTimbau do IMDB teve 91,1% no teste e 66% no ouro. Avaliar só no conjunto de teste do dataset de origem teria levado à escolha errada nos dois casos.

P2 — Críticas nativas melhoram a generalização? Sim, e o efeito foi o maior do estudo. Para o BERTimbau, trocar o IMDB traduzido por 3.192 críticas nativas elevou o recall das negativas no ouro de 0,27 para 0,82. O viés positivo vinha do domínio de treino, não da arquitetura: os dois modelos treinados só no IMDB erraram do mesmo jeito. Combinar as fontes deu o melhor resultado geral.

P3 — O BERTimbau generaliza melhor que a Bi-LSTM? Sim, principalmente com poucos dados. O pré-treinamento em 2,7 bilhões de tokens em português deu ao BERTimbau um conhecimento da língua que a Bi-LSTM precisaria aprender do zero. Com 34 mil exemplos do IMDB, a Bi-LSTM chegou perto (0,886 contra 0,911 no teste do IMDB). Com 3 mil críticas nativas, não aprendeu, enquanto o BERTimbau chegou a 0,870 no Papo de Cinema.

Implicação prática. Para monitorar a recepção de filmes em português, o caminho mais eficaz foi um modelo pré-treinado na língua, ajustado com alguns milhares de críticas do domínio. Coletar dados do domínio certo rendeu mais que aumentar o volume de dados de outro domínio: 3 mil críticas nativas superaram 15 mil traduzidas no conjunto ouro.

Instabilidade da Bi-LSTM. O mesmo cenário (IMDB + nativo) deu F1 de 0,792 no Papo de Cinema com lote de 128 e 0,700 com lote de 32. Uma variação de 9 pontos só por um hiperparâmetro indica que os resultados da Bi-LSTM devem ser lidos com cautela. O BERTimbau foi treinado uma vez por cenário, então sua variabilidade entre execuções não foi medida.

Limitações.

- **Tamanho do conjunto ouro.** Com 50 críticas, as diferenças menores que cerca de 13 pontos não são conclusivas. Os testes nativos, com centenas de críticas, dão estimativas mais firmes.
- **Rotulagem manual sem medida de concordância.** As 40 críticas do Rapadura foram rotuladas pela equipe, sem dupla anotação independente nem medida de concordância entre anotadores, como o kappa de Cohen.
- **Nota como rótulo.** A nota resume a opinião, mas uma crítica pode elogiar partes de um filme com nota baixa. Descartar as notas intermediárias simplifica a tarefa em relação ao mundo real.
- **Custo computacional.** O BERTimbau exigiu liberar a GPU ou usar o Colab, e o tempo de treino limitou os hiperparâmetros a uma configuração padrão (lr 2e-5, 2 épocas), sem busca sistemática.
- **Truncamento.** As críticas profissionais têm mediana de 751 palavras, mas os modelos veem até 200 a 300. Manter início e fim atenua a perda, mas não a elimina.
- **Uma execução por configuração.** Cada modelo foi treinado uma vez por cenário, sem repetir com sementes diferentes. As diferenças pequenas (menos de 2 a 3 pontos no Papo de Cinema) podem não se repetir.
- **Cobertura temporal.** O AdoroCinema foi coletado a partir dos filmes em cartaz, o que concentra o corpus em lançamentos recentes.

8. Conclusão e trabalhos futuros

O Experimento 1 já responde à primeira pergunta de pesquisa: a acurácia no teste não previu o desempenho em críticas reais. O modelo de 95,4% no teste acertou 46% das críticas de cinema. O Experimento 2 respondeu às outras duas: críticas nativas no treino corrigiram o viés dos dados traduzidos, e o BERTimbau superou a Bi-LSTM, sobretudo com

poucos dados. A melhor combinação, BERTimbau com IMDB e críticas nativas, teve F1 de 0,892 em 916 críticas profissionais e 82% de acerto no conjunto ouro, contra 46% do modelo inicial.

Trabalhos futuros.

- Testar o BERTimbau large (cerca de 335 milhões de parâmetros) e fazer uma busca de hiperparâmetros.
- Ampliar o conjunto ouro, com rotulagem por dois anotadores e medida de concordância (kappa de Cohen).
- Classificação em três classes (negativo, neutro, positivo) ou regressão da nota.
- Aplicação: relacionar o sentimento médio previsto por filme com resultados de premiações por voto popular.

Referências

ABADI, M. *et al.* **TensorFlow**: large-scale machine learning on heterogeneous systems. 2015. Disponível em: <https://www.tensorflow.org>. Acesso em: 26 set. 2026.

ADOROCINEMA. **Críticas de espectadores**. Disponível em: <https://www.adorocinema.com>. Acesso em: 26 set. 2026.

CHOLLET, F. *et al.* **Keras**. 2015. Disponível em: <https://keras.io>. Acesso em: 26 set. 2026.

CINEMA COM RAPADURA. **Críticas**. Disponível em: <https://cinemacomrapadura.com.br/criticas/>. Acesso em: 25 set. 2026.

DEVLIN, J. *et al.* BERT: pre-training of deep bidirectional transformers for language understanding. *In*: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES, 2019, Minneapolis. **Proceedings** [...]. Minneapolis: ACL, 2019. p. 4171-4186.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735-1780, 1997.

IMDB PT-BR. **IMDB reviews in Portuguese**. Kaggle, [s. d.]. Disponível em: <https://www.kaggle.com/datasets/luisfredgs/imdb-ptbr>. Acesso em: 26 set. 2026.

MAAS, A. L. *et al.* Learning word vectors for sentiment analysis. *In*: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 49., 2011, Portland. **Proceedings** [...]. Portland: ACL, 2011. p. 142-150.

NEURALMIND. **BERTimbau base (bert-base-portuguese-cased)**. Hugging Face, 2020. Disponível em: <https://huggingface.co/neuralmind/bert-base-portuguese-cased>. Acesso em: 26 set. 2026.

OMELETE. **Críticas**. Disponível em: <https://www.omelete.com.br/criticas>. Acesso em: 25 set. 2026.

PAPO DE CINEMA. **Críticas de filmes**. Disponível em: <https://www.papodecinema.com.br/categoria/filmes/criticas/>. Acesso em: 26 set. 2026.

REAL, L.; OSHIRO, M.; MAFRA, A. B2W-Reviews01: an open product reviews corpus. *In: SYMPOSIUM IN INFORMATION AND HUMAN LANGUAGE TECHNOLOGY*, 12., 2019, Salvador. **Proceedings** [...]. Salvador: SBC, 2019. Dados disponíveis em: <https://github.com/americanas-tech/b2w-reviews01>. Acesso em: 25 set. 2026.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. *In: BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS*, 9., 2020, Rio Grande. **Proceedings** [...]. Cham: Springer, 2020. p. 403-417. (Lecture Notes in Computer Science, v. 12319).

VASWANI, A. *et al.* Attention is all you need. *In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS*, 30., 2017, Long Beach. **Proceedings** [...]. Red Hook: Curran Associates, 2017. p. 5998-6008.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927.